Предсказание стоимости медицинских услуг клиента страховой компании

Задача: **построить модель, прогнозирующую стоимость медицинских услуг** клиента страховой компании

Данные: Medical Costs Dataset

содержат:

- возраст
- пол
- индекс массы тела
- количество детей
- статус курильщика
- регион проживания
- стоимость медицинских услуг

по более чем 1300 клиентам страховой компании. По этому набору данных нужно построить **модель прогноза стоимости медицинских услуг**.

Часть 1. Разведывательный анализ данных

В этом документе описаны:

- Первичный анализ данных
- Анализ целевой переменной
- Анализ взаимосвязей между признаками
- Анализ взаимосвязей между целевой переменной и признаками
- Выводы разведывательного анализа

Данные. Загрузка и первичный анализ

In [1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
```

Данные Medical Costs Dataset сохранены локально в папке data

In [2]:
```
df = pd.read_csv('data/insurance_medical_costs.csv')
```

In [3]:
```
df.head()
```

Out[3]:

	age	sex	bmi	children	smoker	region	charges
0	19	female	27.900	0	yes	southwest	16884.92400
1	18	male	33.770	1	no	southeast	1725.55230
2	28	male	33.000	3	no	southeast	4449.46200
3	33	male	22.705	0	no	northwest	21984.47061
4	32	male	28.880	0	no	northwest	3866.85520

В таблице: целевая переменная `charges` – стоимость медицинских услуг, числовые признаки: `age` (возраст), `bmi` (индекс массы тела), `children` (число детей), категориальные признаки: `sex`, `smoker`, `region`.

In [4]:
```
df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 1338 entries, 0 to 1337
Data columns (total 7 columns):
 #   Column    Non-Null Count  Dtype  
---  ------    --------------  -----  
 0   age       1338 non-null   int64  
 1   sex       1338 non-null   str    
 2   bmi       1338 non-null   float64
 3   children  1338 non-null   int64  
 4   smoker    1338 non-null   str    
 5   region    1338 non-null   str    
 6   charges   1338 non-null   float64
dtypes: float64(2), int64(2), str(3)
memory usage: 73.3 KB
```

Нулевых данных нет

In [5]:
```
df.describe()
```

Out[5]:

	age	bmi	children	charges
count	1338.000000	1338.000000	1338.000000	1338.000000
mean	39.207025	30.663397	1.094918	13270.422265
std	14.049960	6.098187	1.205493	12110.011237
min	18.000000	15.960000	0.000000	1121.873900
25%	27.000000	26.296250	0.000000	4740.287150
50%	39.000000	30.400000	1.000000	9382.033000
75%	51.000000	34.693750	2.000000	16639.912515
max	64.000000	53.130000	5.000000	63770.428010

Первичный анализ с помощью команды df.describe() даёт нам следующее:

Целевая переменная

- очень вариативна: стандартное отклонение std 12110 сравнимо со средним значением mean 13270 (округляю до единиц)
- половина данных charges располагается в диапазоне от 1122 до 9382
- три четверти данных charges не превосходят 16640
- у данных есть длинный "хвост" до 63770 – с ним нужно будет внимательно работать при построении прогноза

Признаки

- возраст: лежит в диапазоне от 18 до 64 (все клиенты совершеннолетние), средний возраст и медиана около 40 лет – почти точно середина диапазона
- индекс массы тела: средняя величина и медиана чуть выше 30, что лежит на границе медицинских категорий "Предожирение" и "Ожирение I степени". При этом согласно медицинской классификации этих терминов "Предожирение" считается изменяемым фактором риска, "Ожирение I степени" уже является диагнозом. Таким образом по показателю индекса массы тела половина клиентов здоровы
- число детей: медиана и среднее около 1, третий квартиль: 2, максимум: 5. Можно сделать вывод, что в нашей выборке много клиентов, у которых нет детей

Анализ целевой переменной

In [6]:
```
mean_charges = np.mean(df['charges'].values)
median_charges = np.quantile(df['charges'].values, q=0.5)
print(f"Среднее: {mean_charges:.2f}")
print(f"Медиана: {median_charges:.2f}")
```

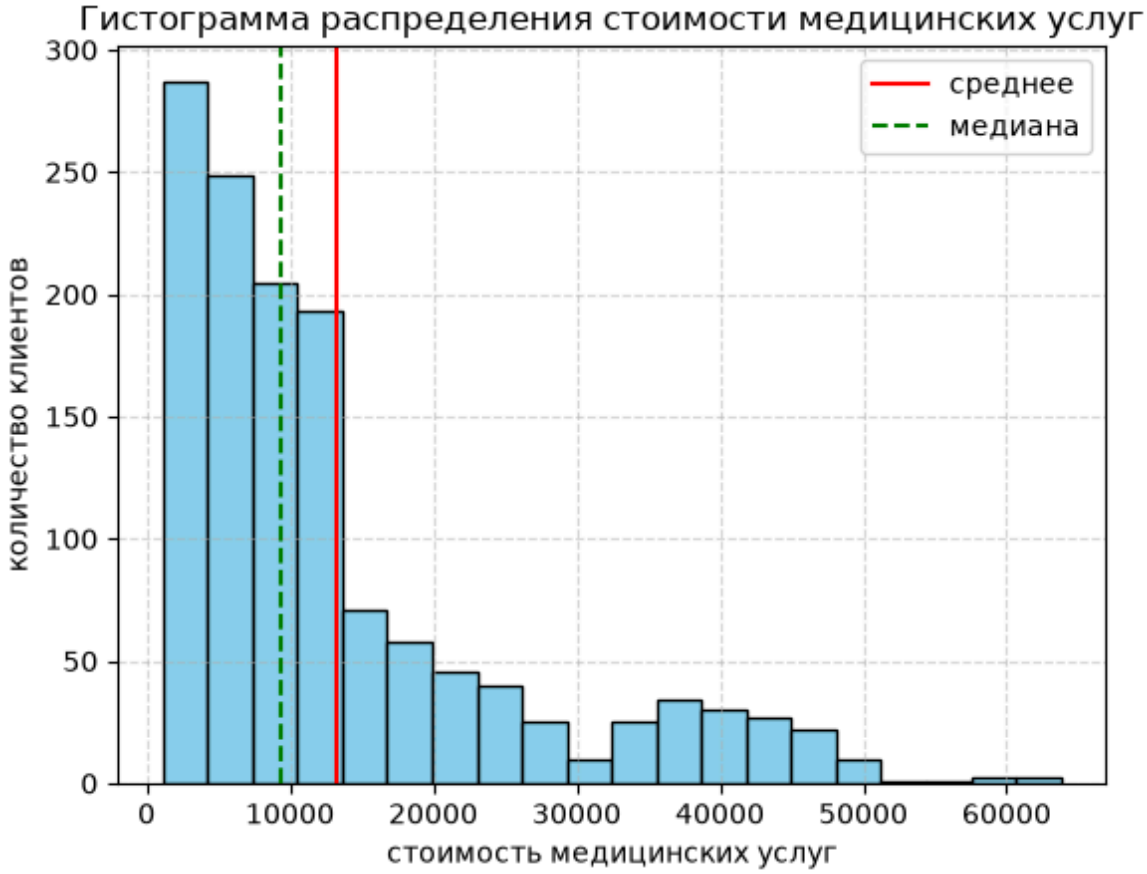
```
Среднее: 13270.42
Медиана: 9382.03
```

Построим гистограмму распределения стоимости медицинских услуг

In [7]:
```
plt.hist(df['charges'], bins=20, color='skyblue', edgecolor='black')

plt.axvline(x=mean_charges, color='r', linestyle = '-', label='среднее')
plt.axvline(x=median_charges, color='g', linestyle = '--', label='медиана')

plt.title('Гистограмма распределения стоимости медицинских услуг')
plt.xlabel('стоимость медицинских услуг')
plt.ylabel('количество клиентов')
plt.legend()
plt.grid(True, linestyle='--', alpha=0.5)
plt.show()
```



Выводы: по гистограмме можно предположить, что примерно половина клиентов страховой компании – это люди, которые всего несколько раз в год пользуются медицинскими услугами (первая группа здоровья). Также у страховой компании есть, должно быть, клиенты с хроническими заболеваниями, которым требуется регулярное медицинское наблюдение и обслуживание. А также могут быть клиенты, которым мог потребоваться большой объём медицинского обслуживания ввиду несчастного случая.

Ожидаемая сложность при прогнозировании: при прогнозировании нужно будет проводить аккуратный выверенный подбор гиперпараметров, чтобы одновременно давать максимально точный прогноз и в среднестатистическом случае, и для случаев высокой стоимости медицинских услуг. Для страховой компании важно предсказывать случаи высоких медицинских затрат. Мы не имеем права отбрасывать сложные случаи. Следует постараться их предсказывать с наименьшим ущербом для оценки затрат в среднестатистическом случае.

Предобработка и анализ признаков

In [8]:
```
df.head()
```

Out[8]:

	age	sex	bmi	children	smoker	region	charges
0	19	female	27.900	0	yes	southwest	16884.92400
1	18	male	33.770	1	no	southeast	1725.55230
2	28	male	33.000	3	no	southeast	4449.46200
3	33	male	22.705	0	no	northwest	21984.47061
4	32	male	28.880	0	no	northwest	3866.85520

Предобработка признака 'smoker'

In [9]:
```
df['smoker'].value_counts()
```

Out[9]:
```
smoker
no     1064
yes     274
Name: count, dtype: int64
```

In [10]:
```
df['smoker'] = df['smoker'].astype(str).str.strip().str.lower().replace({'yes':
df['smoker'] = pd.to_numeric(df['smoker'], errors='coerce')
```

In [11]:
```
df['smoker'].value_counts()
```

Out[11]:
```
smoker
0    1064
1     274
Name: count, dtype: int64
```

Предобработка признака 'region'

In [12]:
```
df['region'].value_counts()
```

Out[12]:
```
region
southeast    364
southwest    325
northwest    325
northeast    324
Name: count, dtype: int64
```

Заметим, что клиентов из всех регионов кроме региона southeast примерно одинаковое количество. Клиентов из региона southeast примерно на 10% больше чем клиентов из какого-либо другого региона.

Руководствуясь здравым смыслом, можно предположить, что регион клиента не является определяющим или важным признаком формирующим стоимость медицинских услуг клиента. Ниже мы проверим этот факт. А пока что используем простой LabelEncoder для преобразования строковых данных колонки 'region' в числа. Таким образом обработанный признак 'region' будет удобнее анализировать.

In [13]:
```
from sklearn.preprocessing import LabelEncoder

encoder = LabelEncoder()
```

```
df['region_labeled'] = encoder.fit_transform(df['region'])
```

In [14]:
```
region_mapping = dict(zip(encoder.classes_, range(len(encoder.classes_))))
print(region_mapping)
```

```
{'northeast': 0, 'northwest': 1, 'southeast': 2, 'southwest': 3}
```

Предобработка оставшихся признаков

Преобразуем оставшиеся признаки (region, sex) с помощью OneHotEncoder

In [15]:
```
from sklearn.preprocessing import OneHotEncoder
```

In [16]:
```
cat_features_list = df.select_dtypes(include=['object', 'str']).columns

encoder = OneHotEncoder(sparse_output=False)
one_hot_encoded = encoder.fit_transform(df[cat_features_list])
one_hot_encoded = pd.DataFrame(one_hot_encoded, columns=encoder.get_feature_name

df = pd.concat([df, one_hot_encoded], axis=1)
df = df.drop(cat_features_list, axis=1)
```

Таблица приобрела следующий вид

In [17]:
```
df.head(3)
```

Out[17]:

	age	bmi	children	smoker	charges	region_labeled	sex_female	sex_male	reg
0	19	27.90	0	1	16884.9240	3	1.0	0.0	
1	18	33.77	1	0	1725.5523	2	0.0	1.0	
2	28	33.00	3	0	4449.4620	2	0.0	1.0	

Сохранение файла

Сохраним таблицу в файл

In [18]:
```
df = df.rename(columns={'region_labeled': 'region'})
```

In [19]:
```
df.head()
```

Out[19]:

	age	bmi	children	smoker	charges	region	sex_female	sex_male	region_nc
0	19	27.900	0	1	16884.92400	3	1.0	0.0	
1	18	33.770	1	0	1725.55230	2	0.0	1.0	
2	28	33.000	3	0	4449.46200	2	0.0	1.0	
3	33	22.705	0	0	21984.47061	1	0.0	1.0	
4	32	28.880	0	0	3866.85520	1	0.0	1.0	

In [20]:
```
df.to_csv('data/medical_costs_preprocessed.csv', index=False, encoding='utf-8-si
```

Для дальнейшего анализа удалим последние колонки

In [21]:
```
df = df.drop(columns=df.columns[df.columns.str.startswith("region_")])
```

In [22]:
```
df.head(3)
```

Out[22]:

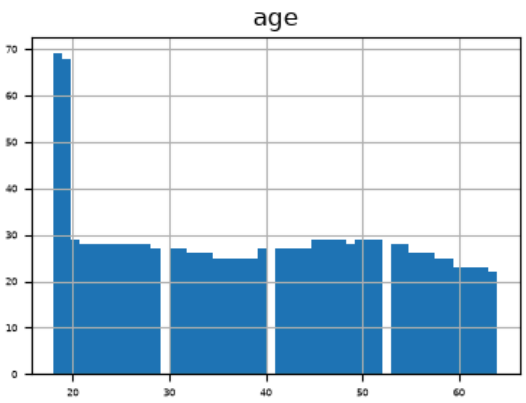
	age	bmi	children	smoker	charges	region	sex_female	sex_male
0	19	27.90	0	1	16884.9240	3	1.0	0.0
1	18	33.77	1	0	1725.5523	2	0.0	1.0
2	28	33.00	3	0	4449.4620	2	0.0	1.0

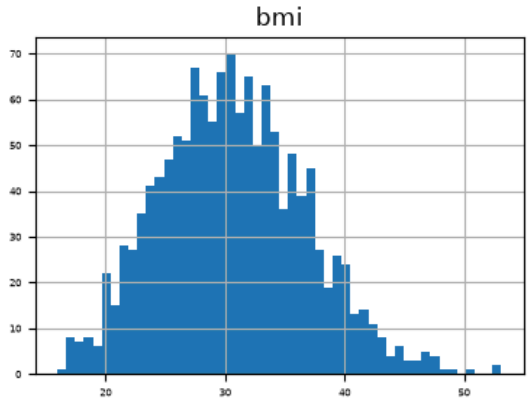
Анализ числовых признаков

In [23]:
```
numerical_columns = ['age', 'bmi']
```

In [24]:
```
num_features = df[numerical_columns]

num_features.hist(figsize=(10, 3), bins=50, xlabelsize=5, ylabelsize=5, grid=Tru
```





Особенности

Можно отметить, что распределение по возрасту клиентов близко к равномерному, за исключением всплеска 18-20 лет. Возможно, это новые клиенты страховой компании, специально таргетированная целевая аудитория.

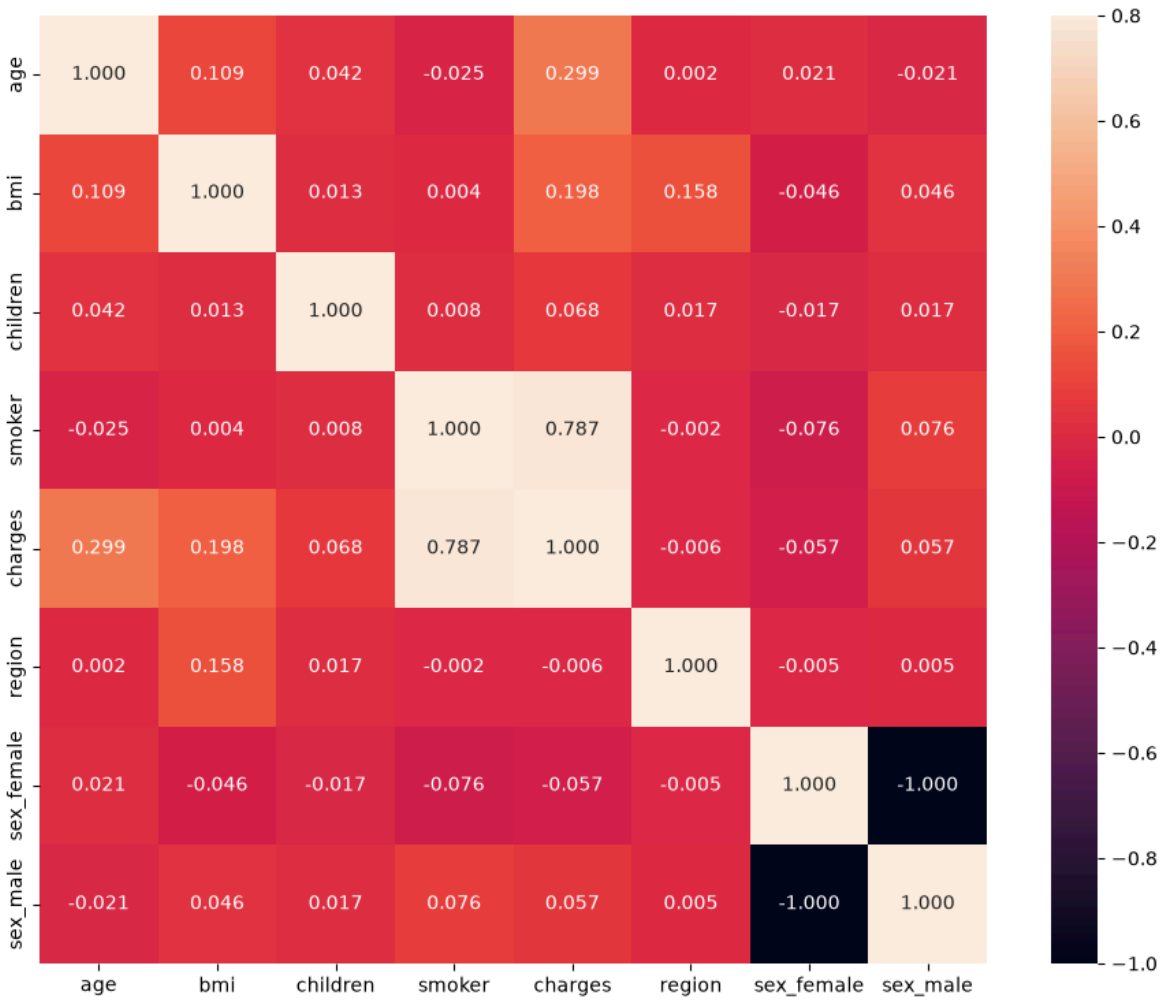
Распределение клиентов по индексу массы тела близко к колоколообразному.

Корреляционная матрица

Рассмотрим корреляционную матрицу по всей таблице

In [25]:
```
import seaborn as sns

corrmat = df.corr()
f, ax = plt.subplots(figsize=(12, 9))
sns.heatmap(corrmat, vmax=.8, square=True, annot=True, fmt='.3f');
```



Особенности

Отметим, что наблюдается **сильная корриляция** между признаком 'smoker' и целевой переменной 'charges' (0,79).

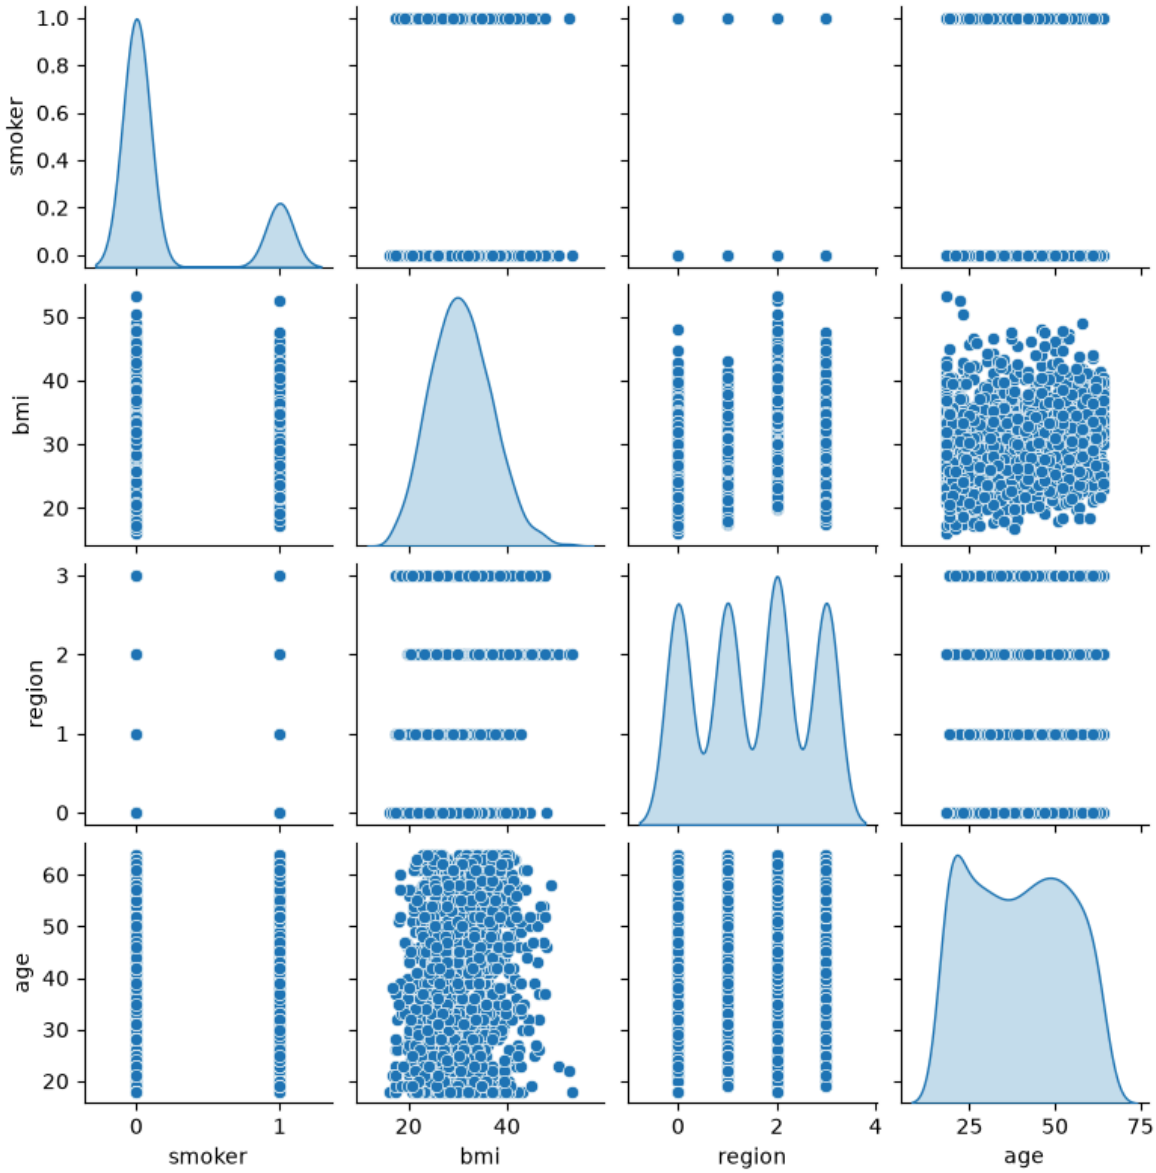
Есть очень слабая положительная связь между признаками 'bmi' и 'region'. Возможно, она связана с особенностями рациона.

Есть очень слабая корреляция между 'age' и 'bmi'. Это закономерно: часть людей с возрастом полнеют. А также между 'age' и 'charges', что тоже естественно.

Обратная корреляция (-1) между признаками sex_female и sex_male естественна: клиент относится строго к одному из полов.

Существенной корреляции между признаками нет. Что также подтверждается графиками ниже

In [26]:
```
sns.pairplot(df, vars = ['smoker', 'bmi', 'region', 'age'], height = 2 , kind ='
plt.show()
```



Анализ взаимосвязей между целевой переменной от признаками

Взаимосвязь целевой переменной и категориальных признаков

Зависимость стоимости медицинских услуг от статуса курильщика

Некурящих в нашей выборке в 3-4 раза больше, чем курящих

In [27]:
```
df['smoker'].value_counts()
```

Out[27]:
```
smoker
0    1064
1     274
Name: count, dtype: int64
```

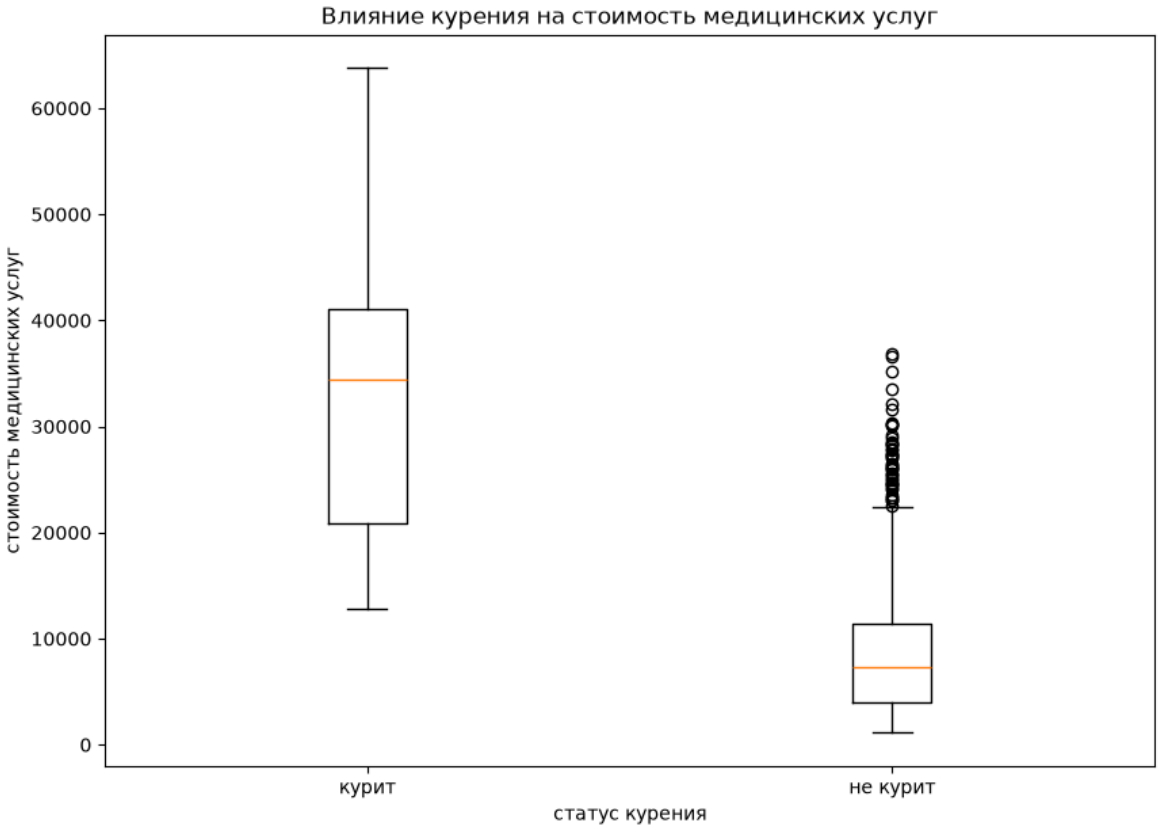
Построим диаграмму ящик с усами для целевой переменной для каждой из категорий ('курит'/'не курит')

In [28]:
```
charges_smoker = df['charges'][df['smoker'] == 1]
charges_nonsmoker = df['charges'][df['smoker'] == 0]

charges_ylabel = 'стоимость медицинских услуг'
```

```
box_figsize = (10, 7)
plt.figure(figsize=box_figsize)

plt.boxplot([charges_smoker, charges_nonsmoker]);
plt.title('Влияние курения на стоимость медицинских услуг');
plt.xlabel('статус курения');
plt.ylabel(charges_ylabel);
plt.xticks([1, 2], ['курит', 'не курит']);
```



На диаграмме оранжевым цветом отмечены медианы стоимости медицинских услуг для курящих и некурящих клиентов соответственно. Нижняя граница каждого из ящиков соответствуют 25% от всех клиентов категории, верхняя – 75%.

Разница значительна: из диаграммы видно, что стоимость медицинских услуг 75% некурящих ниже, чем стоимость услуг 75% курящих. Диаграмма ещё раз подтверждает, что **статус курильщика один из значимых признаков при оценке стоимости медицинских услуг**.

Зависимость стоимости медицинских услуг от пола

In [29]:
```
charges_female = df['charges'][df['sex_female'] == 1]
charges_male = df['charges'][df['sex_male'] == 1]
```

In [30]:
```
median_female = np.quantile(charges_female.values, q=0.5)
median_male = np.quantile(charges_male.values, q=0.5)
```

In [31]:
```
print(f'число женщин: {charges_female.size}\nчисло мужчин: {charges_male.size}')
```

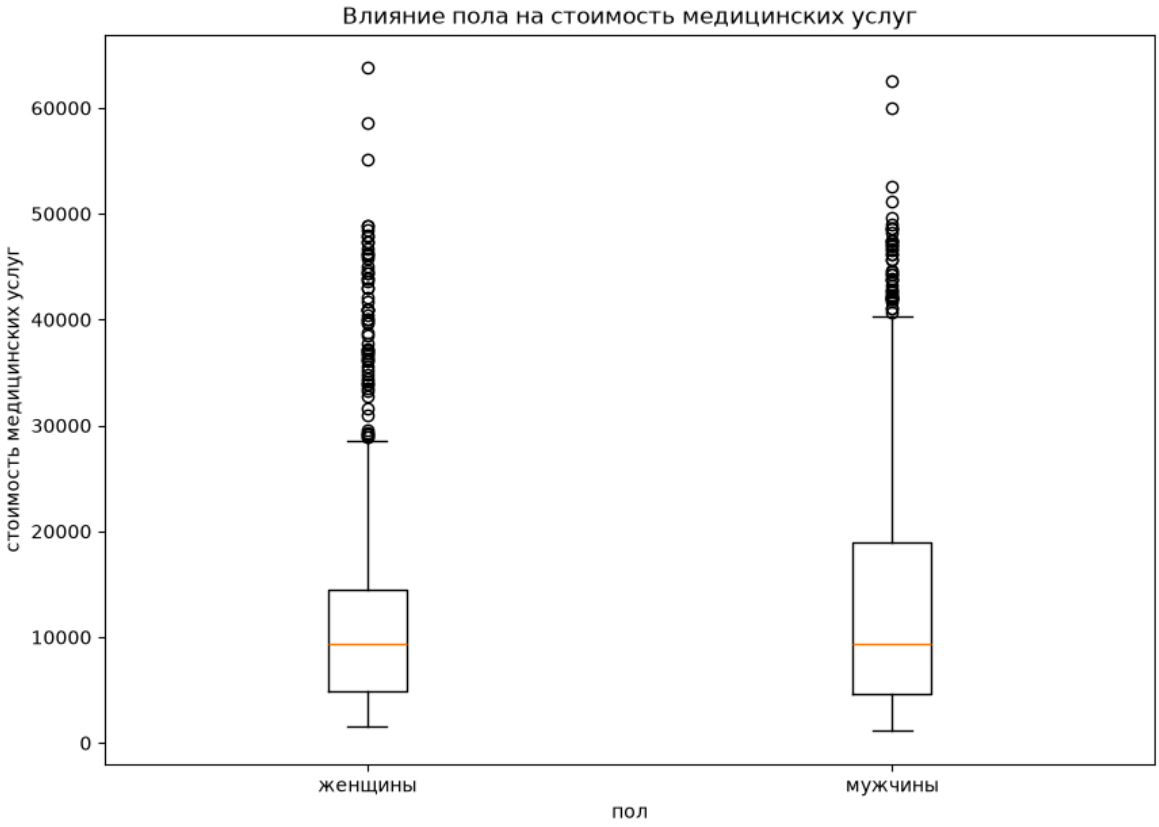
```
число женщин: 662
число мужчин: 676
```

In [32]:
```
print(f'медиана (женщины): {median_female}\nмедиана (мужчины): {median_male}')
```

```
медиана (женщины): 9412.9625
медиана (мужчины): 9369.61575
```

Мужчин и женщин в нашем наборе примерно поровну. Медианы двух категорий очень близки

In [33]:
```
plt.figure(figsize=box_figsize)
plt.boxplot([charges_female, charges_male]);
plt.title('Влияние пола на стоимость медицинских услуг');
plt.xlabel('пол');
plt.ylabel(charges_ylabel);
plt.xticks([1, 2], ['женщины', 'мужчины']);
```



Медианы двух категорий близки между собой. Межквартильный размах для мужчин больше, чем для женщин – за счёт более высокого уровня третьего квартиля – границы 75%.

Примерно для 50% данных различия в стоимости услуг несущественны. Можно даже предположить, что пол может быть избыточным данным при обучении некоторых моделей.

Взаимосвязь между стоимостью услуг и регионом

In [34]:
```
region_mapping
```

Out[34]:
```
{'northeast': 0, 'northwest': 1, 'southeast': 2, 'southwest': 3}
```

In [35]:
```
region_means = df.groupby('region')['charges'].mean()
region_means_dict = {k: round(float(region_means[v]), 2) for k, v in region_mapp
```

```
print('Средние значения стоимости медицинских услуг по регионам:')
print(region_means_dict)
```

```
Средние значения стоимости медицинских услуг по регионам:
{'northeast': 13406.38, 'northwest': 12417.58, 'southeast': 14735.41, 'southwes
t': 12346.94}
```

In [36]:
```
region_dist = df['region'].value_counts()
print(region_dist)
```

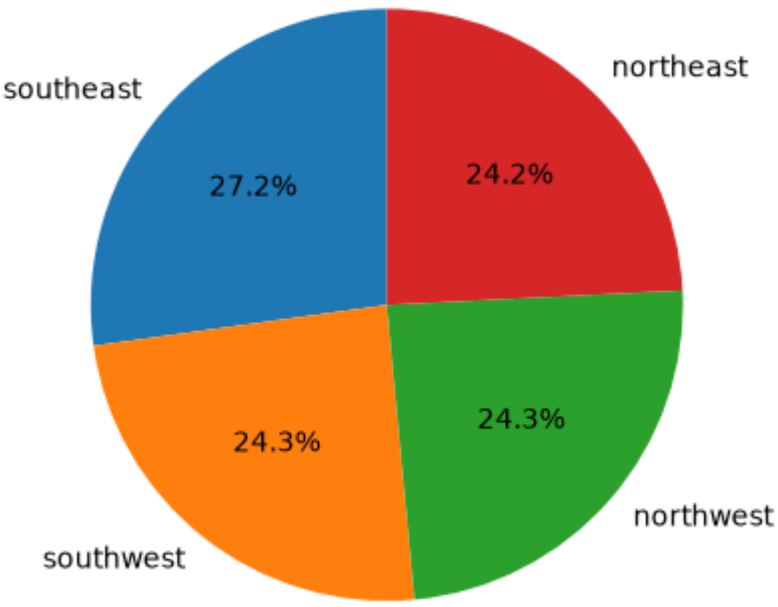
```
region
2    364
3    325
1    325
0    324
Name: count, dtype: int64
```

In [37]:
```
def get_region_labels(rg_dist, rg_map):
    return [label
            for j in rg_dist.index
            for label, i in rg_map.items()
            if i == j]

region_labels = get_region_labels(region_dist, region_mapping)
region_labels
```

Out[37]:
```
['southeast', 'southwest', 'northwest', 'northeast']
```

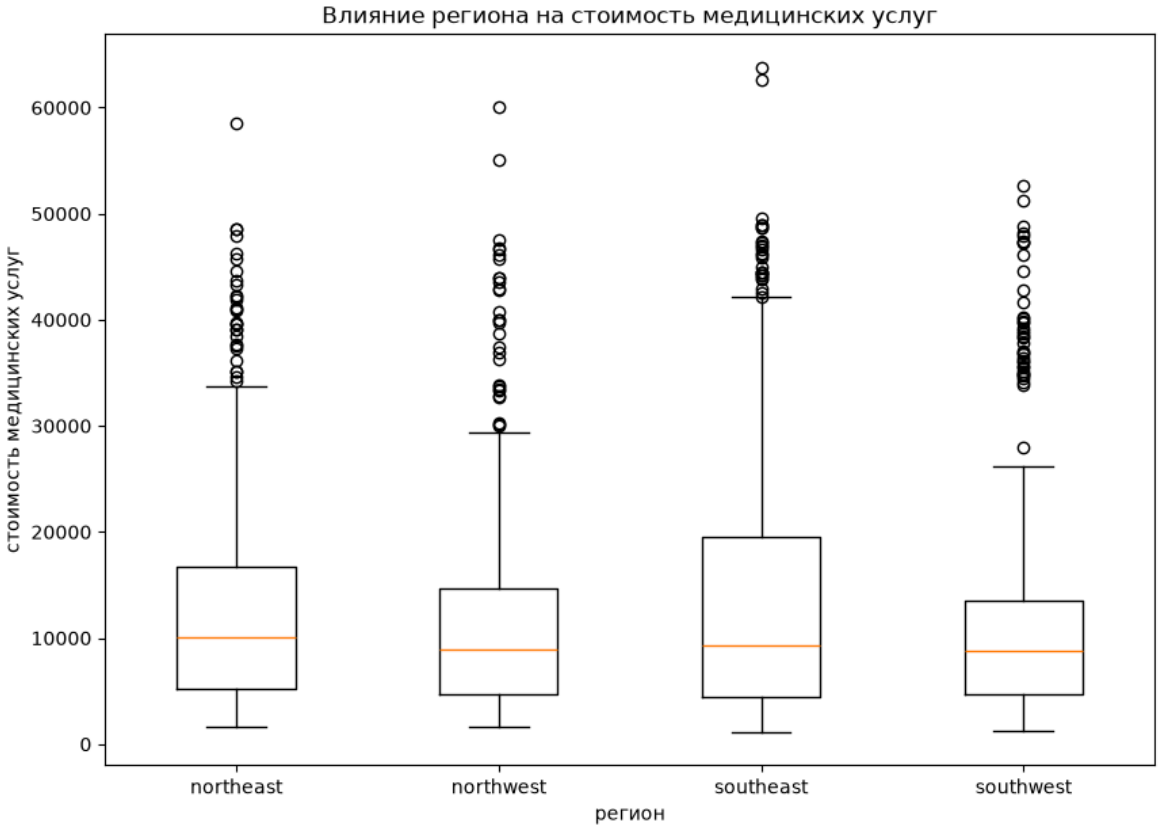
In [38]:
```
plt.pie(region_dist, autopct='%1.1f%%', labels=region_labels, startangle=90);
```



In [39]:
```
charges_region = [df['charges'][df['region'] == i] for i in region_mapping.value

plt.figure(figsize=box_figsize);
plt.boxplot(charges_region);
plt.title('Влияние региона на стоимость медицинских услуг');
plt.xlabel('регион');
```

```
plt.ylabel(charges_ylabel);
plt.xticks(range(1, len(region_mapping) + 1), region_mapping.keys());
```



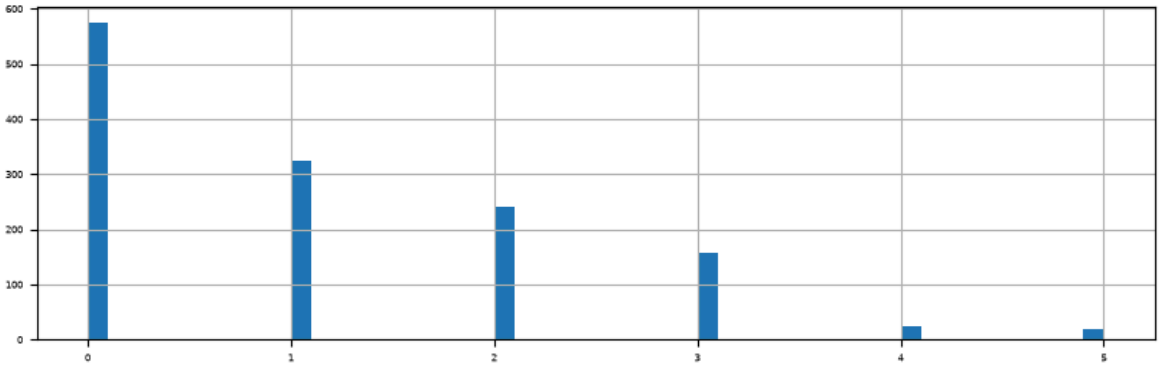
Выводы:

- все регионы представлены равномерно (исключение: клиентов из southeast несколько больше, чем из других регионов)
- первая и вторая квартиль по всем регионам близки между собой
- **регион, возможно, является неинформативным признаком**, который может создавать шум при обучении

Взаимосвязь между стоимостью услуг и количеством детей

Представим схематично распределение по количеству детей

In [40]:
```
df['children'].hist(figsize=(10, 3), bins=50, xlabelsize=5, ylabelsize=5, grid=T
```



In [41]:
```
df['children'].value_counts()
```

Out[41]:
```
children
0    574
1    324
2    240
3    157
4     25
5     18
Name: count, dtype: int64
```

Посмотрим на то, как влияет число детей на стоимость медицинских услуг клиента также в зависимости от пола родителей

In [42]:
```
children_max = df['children'].max()
children_range_max = children_max + 1
charges_female_children = [charges_female[df['children'] == i] for i in range(ch
charges_male_children = [charges_male[df['children'] == i] for i in range(childr
charges_children_all = [df['charges'][df['children'] == i] for i in range(childr

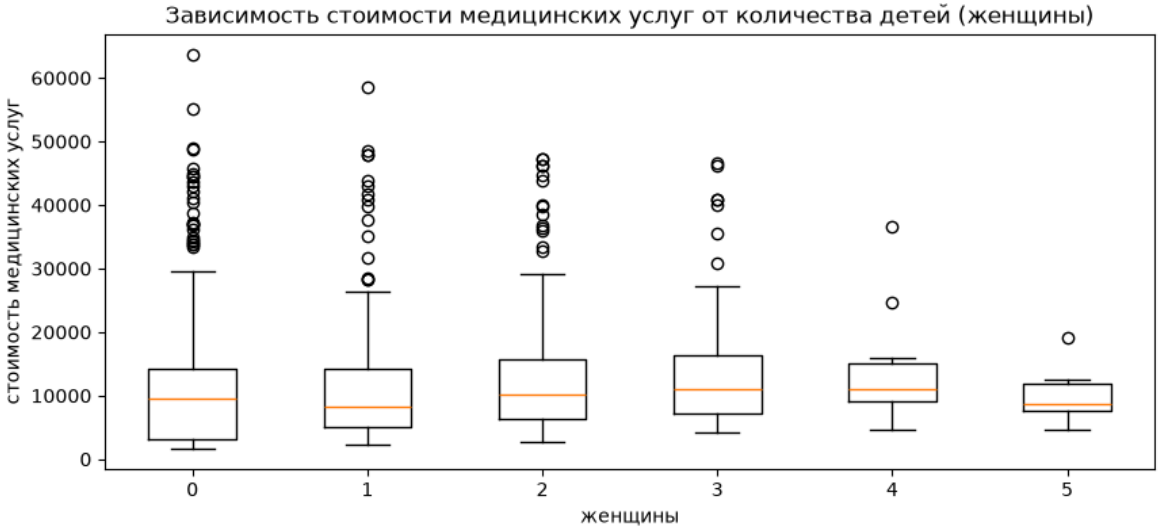
charges_children = {'женщины': charges_female_children, 'мужчины': charges_male_
```

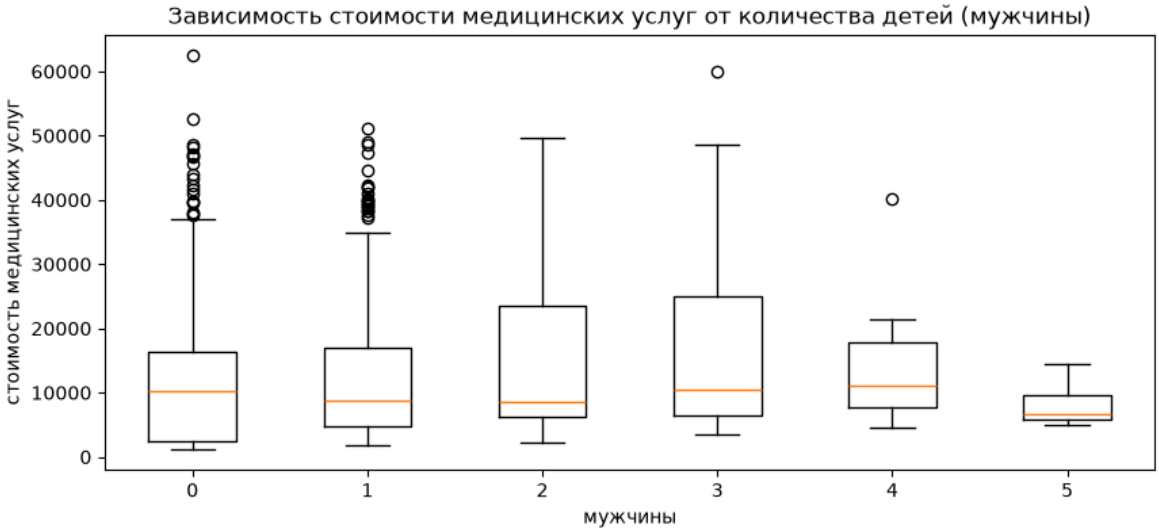
In [43]:
```
n_rows = len(charges_children)
fig, axes = plt.subplots(n_rows, 1, figsize=(10, 5 * n_rows), squeeze=False)
axes = axes.flatten()

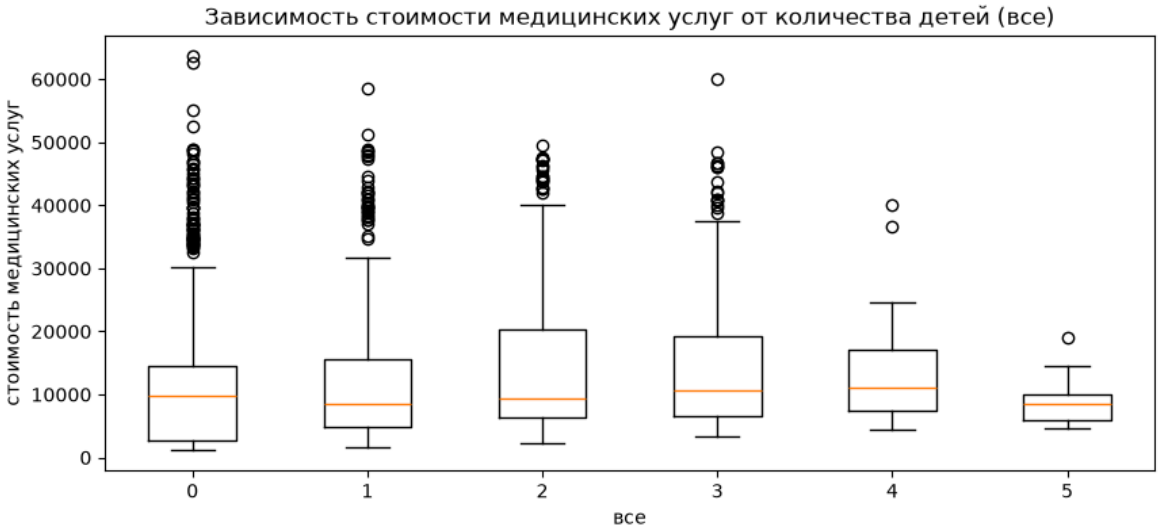
for i, key in enumerate(charges_children):
    ax = axes[i]

    ax.boxplot(charges_children[key])
    ax.set_xlabel(key)
    ax.set_ylabel(charges_ylabel)
    ax.set_title(f'Зависимость стоимости медицинских услуг от количества детей (
    ax.set_xticks(range(1, children_range_max + 1), range(children_range_max))

plt.subplots_adjust(hspace=0.3)
plt.show()
```







Выводы:

- среди клиентов страховой компании больше всего клиентов без детей (574 человека)
- при большом количестве детей 4 и 5 мы имеем всего 25 и 18 клиентов, соответственно
- количество детей информативный признак

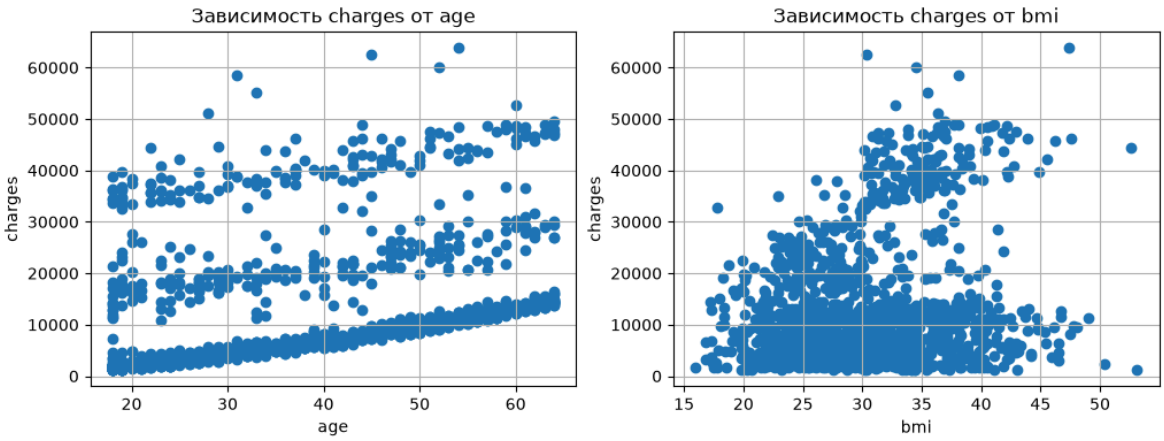
Взаимосвязь между стоимостью услуг и числовыми признаками

In [44]:
```
target = 'charges'
n_cols = len(numerical_columns)
n_rows = 1

fig, axes = plt.subplots(n_rows, n_cols, figsize=(12, 4 * n_rows), squeeze=False
axes = axes.flatten()

for i, feat in enumerate(num_features):
    ax = axes[i]
    ax.scatter(df[feat], df[target])
    ax.set_xlabel(feat)
    ax.set_ylabel(target)
    ax.set_title(f'Зависимость {target} от {feat}')
    ax.grid(True)

plt.show()
```



Наблюдения:

- примечательно, что на графике зависимости стоимости медицинских услуг от возраста видно три разных линейных тренда
- на графике зависимости стоимости медицинских услуг от индекса массы тела видна слабая линейная корреляция

Уточнение данных по клиентам с высоким уровнем медицинских расходов

Разобьём все данные на группы. Первые три группы соответствуют первым трём квартилям по стоимости медицинских услуг. Третья и четвёртая группа – это следующие 20%, разбитые пополам, последняя группа – оставшиеся 5%.

In [45]:
```
charges_qnt = np.quantile(df['charges'].values, [0, 0.25, 0.5, 0.75, 0.85, 0.95,
print(charges_qnt)
```

```
[ 1121.8739     4740.28715    9382.033     16639.912515  24990.1669955
 41181.8277875 63770.42801   ]
```

In [46]:
```
df['group'] = pd.cut(df[target], bins=charges_qnt, include_lowest=True)
```

In [47]:
```
grouped = df.groupby('group')
```

```
display(grouped.size())
```

```
group
(1121.873, 4740.287]      335
(4740.287, 9382.033]      334
(9382.033, 16639.913]     334
(16639.913, 24990.167]    134
(24990.167, 41181.828]    134
(41181.828, 63770.428]     67
dtype: int64
```

Посмотрим на средние характеристики групп

In [48]:
```
display(grouped.mean().round(2))
```

group	age	bmi	children	smoker	charges	region	sex_female	sex_male
(1121.873, 4740.287]	23.81	29.91	0.62	0.00	2853.09	1.54	0.48	0.52
(4740.287, 9382.033]	40.23	30.32	1.52	0.00	6991.86	1.59	0.51	0.49
(9382.033, 16639.913]	52.64	31.11	1.06	0.06	12106.07	1.44	0.55	0.45
(16639.913, 24990.167]	36.72	27.70	1.26	0.65	20571.65	1.37	0.49	0.51
(24990.167, 41181.828]	38.57	32.07	1.07	0.75	33906.82	1.53	0.41	0.59
(41181.828, 63770.428]	50.36	37.01	1.24	1.00	46585.29	1.64	0.39	0.61

Наблюдения:

- средний статус курильщика строго возрастает от 0 до 1
- средние характеристики возраста и количества детей не показывают *линейного* тренда
- По признаку индекса массы тела ('bmi') средние значения по всем группам близки к 30, за исключением группы последних 5%
- распределение по полам практически равномерное, за исключением последних 5%

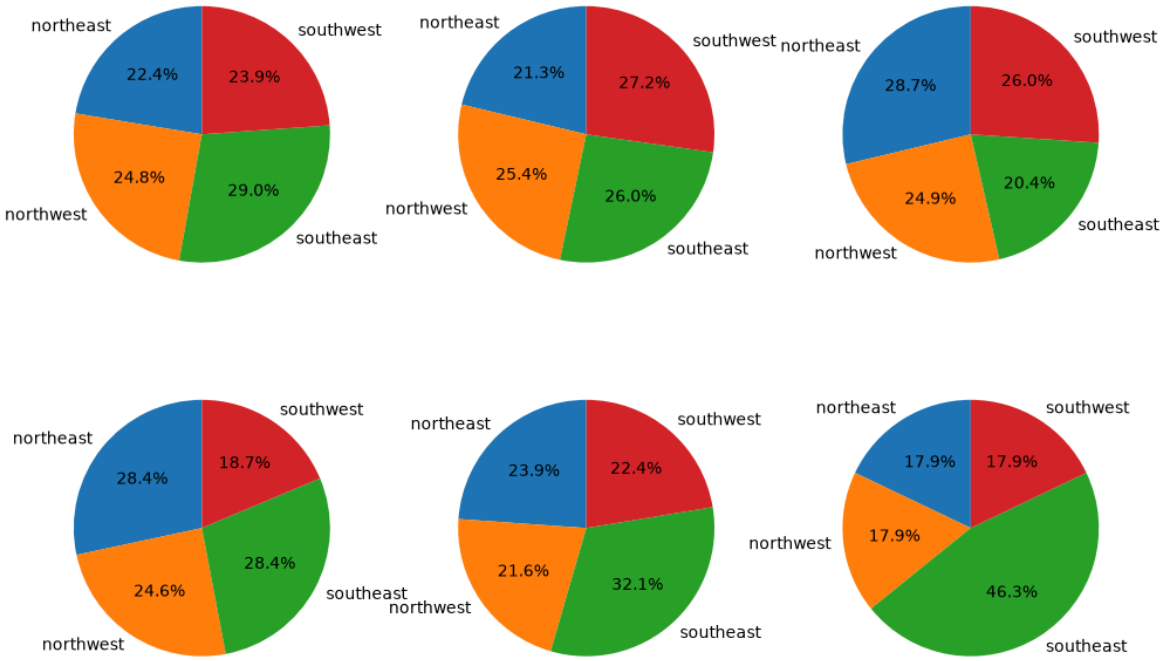
Проверим равномерность распределения по регионам в каждой из выделенных групп

In [49]:
```
n_cols = 3
n_rows = len(df.groupby('group')) // n_cols + (len(df.groupby('group')) % n_cols
fig, axes = plt.subplots(n_rows, n_cols, figsize=(12, 4 * n_rows), squeeze=False
axes = axes.flatten()

for i, (group_name, group_df) in enumerate(grouped):
    ax = axes[i]
```

```
    region_counts = group_df['region'].value_counts().sort_index()

    ax.pie(region_counts, labels=get_region_labels(region_counts, region_mapping
```



Распределение клиентов по регионам в первых трёх группах (первые три квантиля) близко к равномерному. В последних двух группах (15% всех клиентов) – клиенты с самой высокой стоимостью медицинских услуг преобладают клиенты из региона southeast

Посмотрим пристальнее на последнюю группу – это 5% клиентов с максимальной стоимостью медицинских услуг, диапазон (41181.828, 63770.428]

In [50]:
```
last_group_df = df[df['group'] == df['group'].max()]
```

In [51]:
```
len(last_group_df)
```

Out[51]: 67

In [52]:
```
last_group_df[last_group_df['smoker'] == 0]
```

Out[52]:

	age	bmi	children	smoker	charges	region	sex_female	sex_male	group

In [53]:
```
last_group_df[last_group_df['children'] > 3]
```

Out[53]:

	age	bmi	children	smoker	charges	region	sex_female	sex_male	group

In [54]:
```
last_group_df[last_group_df['bmi'] < 25]
```

Out[54]:

	age	bmi	children	smoker	charges	region	sex_female	sex_male	group

In [55]:
```
last_group_df[last_group_df['age'] < 35]
```

Out[55]:

	age	bmi	children	smoker	charges	region	sex_female	sex_male	g
34	28	36.400	1	1	51194.55914	3	0.0	1.0	(4118 63770
292	25	45.540	2	1	42112.23560	2	0.0	1.0	(4118 63770
577	31	38.095	1	1	58571.07448	0	1.0	0.0	(4118 63770
587	34	30.210	1	1	43943.87610	1	1.0	0.0	(4118 63770
739	29	35.500	2	1	44585.45587	3	0.0	1.0	(4118 63770
819	33	35.530	0	1	55135.40209	1	1.0	0.0	(4118 63770
1047	22	52.580	1	1	44501.39820	2	0.0	1.0	(4118 63770

In [56]:
```
region_mapping
```

Out[56]:
```
{'northeast': 0, 'northwest': 1, 'southeast': 2, 'southwest': 3}
```

Итого, 67 человек (5% от всех) с самыми высокими расходами на медицинские услуги:

- **ВСЕ курят**
- имеют не более 3 детей
- их ИМТ больше 25 (выше нормы)

Выводы разведывательного анализа

На основе анализа можно ранжировать признаки по их значимости:

- числовые:
  - возраст, индекс массы тела (bmi) – примерно одинаково релевантны, корреляция с целевой переменной слабая
  - количество детей – релевантный дискретный числовой признак
- категориальные:
  - **статус курильщика** – значимый признак: **корреляция с целевой переменной: 0.79**
  - пол – менее важный признак
  - регион – малорелевантный, возможно, избыточный

Ввиду отсутствия явных зависимостей (линейной или полиномиальной) между признаками и целевой переменной, поставленную задачу регрессии (предсказания стоимости медицинских услуг) имеет смысл реализовать с помощью ансамблевых

алгоритмов основывающихся на решающих деревьях. В качестве первого приближения можно также рассмотреть модель k ближайших соседей

Таким образом, **модели для прогноза стоимости медицинских услуг**, согласно предполагаемой эффективности:

- k-Nearest Neighbors – самый быстрый, годится как первое приближение, для сравнения с более сложными алгоритмами
- Random Forest Regressor
- Gradient Boosting – будет требовать наибольших ресурсов и наиболее аккуратной настройки

Метрики для оценки моделей:

- Mean Absolute Error – для оценки среднего отклонения от истинных значений
- Mean Absolute Percentage Error – безразмерная оценка относительно величины целевых значений
- Root Mean Squared Error – для более точного приближения экстремально больших значений

In [ ]: